Matrix Factorization (TT)

PCA & SVD trong lọc cộng tác

DS300
HỆ KHUYẾN NGHỊ

Giảng viên: **ThS. Huỳnh Văn Tín**
Bộ môn Khoa học Dữ liệu
Khoa Khoa học và Kỹ thuật Thông tin

Mục tiêu và lộ trình buổi học

Sau buổi học, sinh viên có thể:

- Giải thích ý tưởng **yếu tố ẩn** và phân rã $R \approx P \cdot Q^T$
- Thực hiện **PCA** từng bước trên ví dụ nhỏ, chọn số thành phần K
- Phân tích **SVD**, xấp xỉ hạng k và nêu quan hệ PCA ↔ SVD
- Dùng SVD/MF để **dự đoán rating** và nhận diện hạn chế

1. Đặt vấn đề · Yếu tố ẩn · PCA trực quan
2. Thuật toán PCA · Ví dụ số · Chọn K
3. SVD · Truncated SVD · PCA ↔ SVD
4. SVD cho khuyến nghị · Funk SVD · Thực hành ví dụ

PHẦN 1

Đặt vấn đề

- Hạn chế của lọc cộng tác dựa trên bộ nhớ
- Ý tưởng yếu tố ẩn (latent factors)
- Phân rã ma trận $R \approx P \cdot Q^T$

Nhắc lại: lọc cộng tác dựa trên bộ nhớ

User-based CF

$$pred(a,i) = \bar{r}_a + \Sigma\, sim(a,u)(r_{u,i} - \bar{r}_u) \,/\, \Sigma|sim(a,u)|$$

Item-based CF

$$pred(u,i) = \Sigma\, sim(i,j)\, r_{u,j} \,/\, \Sigma|sim(i,j)|$$

Mọi dự đoán đều tính **trực tiếp trên ma trận rating** → gọi là phương pháp dựa trên bộ nhớ (memory-based).

	Item1	Item2	Item3	Item4	Item5
Alice	5	3	4	4	**?**
User1	3	1	2	3	3
User2	4	3	4	3	5
User3	3	3	1	5	4
User4	1	5	5	2	1

Cần dự đoán rating của Alice cho Item5

Ba hạn chế của CF dựa trên bộ nhớ

1

Dữ liệu thưa

Hai user hiếm khi cùng đánh giá một item → độ tương đồng tính trên rất ít điểm chung, kém tin cậy.

2

Số chiều lớn

Vector user có hàng chục nghìn chiều (mỗi item một chiều); khoảng cách, cosine khó phân biệt user gần/xa.

3

Chi phí tính toán

Mỗi lần dự đoán phải duyệt lại ma trận rating → khó mở rộng cho hàng triệu user và item.

Câu hỏi: có thể **nén** ma trận rating thành vài "yếu tố" cô đọng, rồi dự đoán từ đó không?

Ma trận rating thực tế rất thưa

Dense Matrix

1	2	31	2	9	7	34	22	11	5
11	92	4	3	2	2	3	3	2	1
3	9	13	8	21	17	4	2	1	4
8	32	1	2	34	18	7	78	10	7
9	22	3	9	8	71	12	22	17	3
13	21	21	9	2	47	1	81	21	9
21	12	53	12	91	24	81	8	91	2
61	8	33	82	19	87	16	3	1	55
54	4	78	24	18	11	4	2	99	5
13	22	32	42	9	15	9	22	1	21

Sparse Matrix

1	.	3	.	9	.	3	.	.	.
11	.	4	.	.	.	.	.	2	1
.	.	1	.	.	.	4	.	1	.
8	.	.	.	3	1	.	.	.	.
.	.	.	9	.	.	1	.	17	.
13	21	.	9	2	47	1	81	21	9
.	.	.	.	.	.	.	.	.	.
.	.	.	.	19	8	16	.	.	55
54	4	.	.	.	11	.	.	.	.
.	.	2	.	.	.	.	22	.	21

Ma trận dày và ma trận thưa

≈ 1,2%

số ô có rating trong dữ liệu Netflix Prize

- 480.189 user × 17.770 phim
- ≈ 8,5 tỉ ô, chỉ ~100 triệu rating
- Ô trống = **chưa biết**, không phải 0

Từ "bộ nhớ" đến "mô hình"

Dựa trên bộ nhớ

Memory-based

- Dùng trực tiếp ma trận rating khi dự đoán
- Đơn giản, dễ giải thích
- Chậm khi dữ liệu lớn, nhạy với độ thưa
- Ví dụ: user-based, item-based CF

Dựa trên mô hình

Model-based

- Học mô hình **offline** từ dữ liệu
- Dự đoán **online** nhanh từ mô hình đã học
- Khái quát hóa tốt hơn trên dữ liệu thưa
- Ví dụ: **Matrix Factorization**, mô hình xác suất, luật kết hợp

Buổi này tập trung vào nhóm Matrix Factorization: PCA → SVD → Funk SVD

Ý tưởng: yếu tố ẩn (latent factors)

Giả thuyết: rating sinh ra từ một số ít yếu tố **không quan sát được** của user và item.

Vector sở thích của Alice: p_{Alice}

Hành động	Viễn tưởng	Tình cảm
0.4	0.2	1.5

Alice ít thích phim hành động, rất thích phim tình cảm.

$$\hat{r}_{ui} = p_u \cdot q_i$$

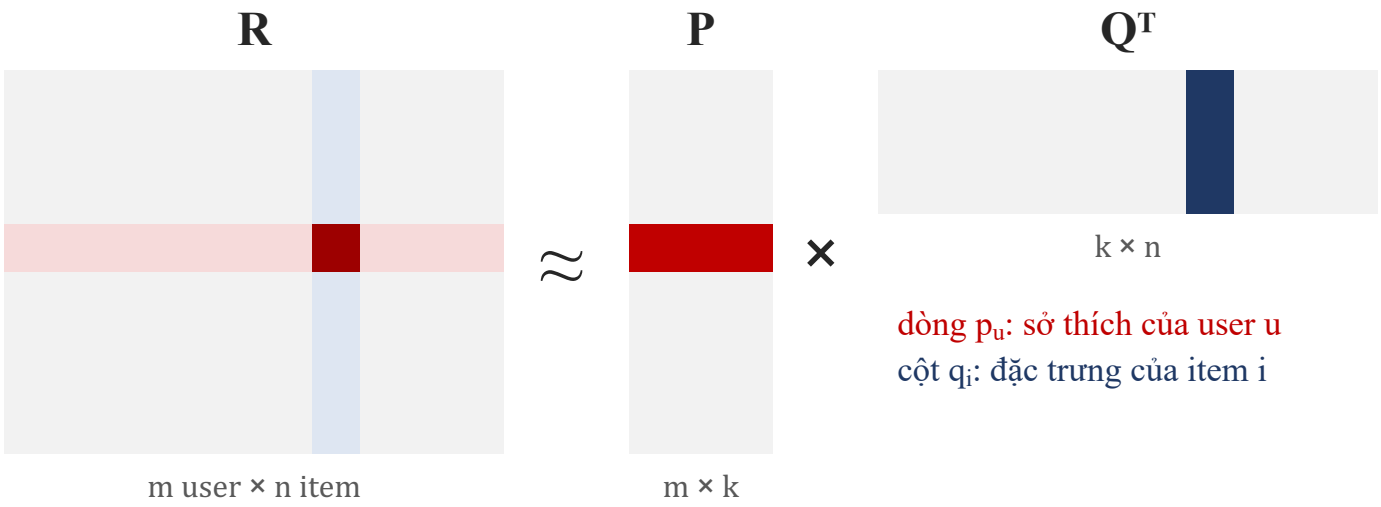
Vector đặc trưng của phim: q_i

Phim	Hành động	Viễn tưởng	Tình cảm	p·q	Thật
The Godfather	1.5	0.0	2.8	**4.8**	5
Terminator	2.0	2.5	0.0	**1.3**	1
Titanic	0.3	0.0	2.6	**4.0**	4

Ví dụ: $0.4\times1.5 + 0.2\times0.0 + 1.5\times2.8 = 4.8 \approx 5$

(số liệu minh họa)

Phân rã ma trận: $R \approx P \cdot Q^T$



dòng p_u: sở thích của user u

cột q_i: đặc trưng của item i

$$\hat{r}_{ui} = p_u \cdot q_i = \Sigma_{f=1..k}\, p_{uf}\, q_{if}$$

- $k \ll m, n$ (thường 10–200)
- 1000 × 1000, k = 5: chỉ **10.000** tham số
- **Tìm P, Q thế nào? → PCA, SVD, Funk SVD**

PHẦN 2

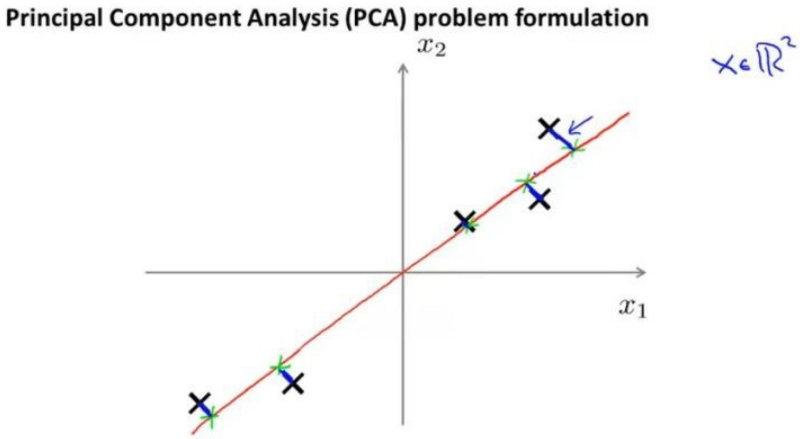
Phân tích thành phần chính (PCA)

- Ý tưởng và trực quan
- Tiền xử lý dữ liệu
- Thuật toán 5 bước và ví dụ số
- Chọn số thành phần K

PCA: ý tưởng

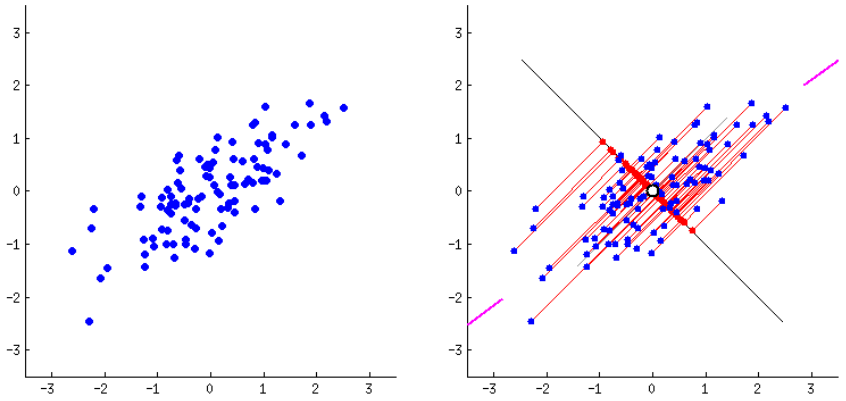
Principal Component Analysis

- Tìm **k hướng** (thành phần chính) để chiếu dữ liệu n chiều xuống k chiều, k < n.
- Hai cách nhìn tương đương:
  - cực đại **phương sai** sau khi chiếu
  - cực tiểu **sai số chiếu** (khoảng cách vuông góc)
- Các thành phần chính **trực giao**, xếp theo phương sai giảm dần.
- Là phương pháp **không giám sát**: không có biến mục tiêu.

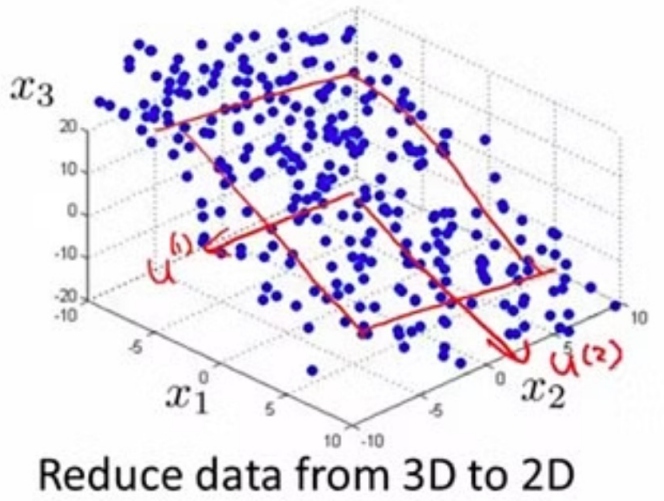


Chiếu dữ liệu 2D lên một đường thẳng (1D)

Trực quan: giảm từ 2D → 1D và 3D → 2D



2D → 1D: chiếu lên thành phần chính thứ nhất

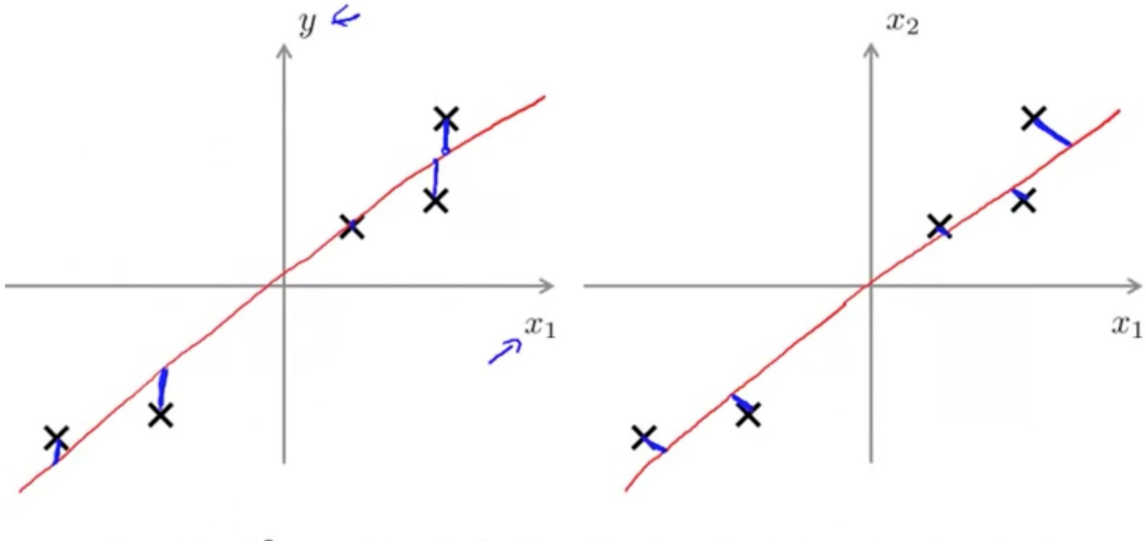


3D → 2D: chiếu lên mặt phẳng ($u^{(1)}$, $u^{(2)}$)

Trong hệ khuyến nghị: mỗi user là một điểm trong không gian n item. PCA tìm vài **trục sở thích** chính.

PCA không phải hồi quy tuyến tính

Tùy chọn



Hồi quy tuyến tính **PCA**

	Hồi quy tuyến tính	PCA
Biến	Có biến mục tiêu y	Mọi biến bình đẳng
Sai số	Theo phương thẳng đứng	Khoảng cách vuông góc
Mục đích	Dự đoán y	Nén dữ liệu, tìm cấu trúc ẩn

Tiền xử lý dữ liệu trước PCA

Trừ trung bình *Mean normalization*	$x' = x - \mu_j$	Bắt buộc: đưa trung bình mỗi đặc trưng về 0
Chuẩn hóa độ lệch chuẩn *Standardization*	$x' = (x - \mu_j) / \sigma_j$	Khi các đặc trưng có thang đo khác nhau
Tỉ lệ min–max *Min-max scaling*	$x' = (x - \min)/(\max - \min)$	Đưa về đoạn [0, 1]

- μ_j, σ_j: trung bình và độ lệch chuẩn của **cột j**; $\sigma_j = \sqrt{(\Sigma_i (x_{ij} - \mu_j)^2 / (m - 1))}$
- Trừ trung bình **theo dòng** (từng user) là bước **đặc thù của dữ liệu rating**, không phải bước bắt buộc của PCA (xem slide sau).

User-mean centering trong dữ liệu rating

Trước: rating gốc

	M1	M2	M3	M4	TB
A (khắt khe)	2	1	2	1	**1.5**
B	3	3	4	2	**3.0**
C (rộng tay)	5	4	5	4	**4.5**

Sau: $r'_{ui} = r_{ui} - \bar{r}_u$

	M1	M2	M3	M4
A	**0.5**	**−0.5**	**0.5**	**−0.5**
B	0	0	1	−1
C	**0.5**	**−0.5**	**0.5**	**−0.5**

Chỉ trừ TB theo cột (PCA thông thường)

PC1 học "ai chấm cao, ai chấm thấp"

Trừ TB user trước, rồi PCA

PC1 học "ai thích loại phim nào": A và C cùng mẫu hình

Thuật toán PCA: 5 bước

1	**Chuẩn hóa**	$X \leftarrow X - \mu$	trừ trung bình mỗi cột
2	**Hiệp phương sai**	$C = X^T X / (m - 1)$	ma trận n × n
3	**Trị riêng, vector riêng**	$C\, v_j = \lambda_j\, v_j$	v_j: thành phần chính
4	**Chọn k thành phần**	$V_k = [v_1 \ldots v_k]$	$\lambda_1 \geq \lambda_2 \geq \ldots \geq \lambda_n$
5	**Chiếu dữ liệu**	$Z = X\, V_k$	ma trận m × k

Trong thực tế, bước 2–3 thường được thay bằng SVD của X (xem Phần 3).

Ví dụ số (1): trừ trung bình và ma trận hiệp phương sai

Dữ liệu A

HS	Toán	Lý	Anh
HS1	90	80	40
HS2	90	60	80
HS3	60	50	70
HS4	30	40	70
HS5	30	20	90
TB μ	**60**	**50**	**70**

X = A − μ

HS	Toán	Lý	Anh
HS1	30	30	−30
HS2	30	10	10
HS3	0	0	0
HS4	−30	−10	0
HS5	−30	−30	20

$C = X^T X / 4$

C	Toán	Lý	Anh
Toán	**900**	600	−300
Lý	600	**500**	−350
Anh	−300	−350	**350**

- Đường chéo: phương sai
- Toán–Lý: +600 (cùng chiều)
- Toán–Anh: −300 (ngược chiều)

$$C_{11} = (30^2 + 30^2 + 0^2 + 30^2 + 30^2) / 4 = 900$$

Ví dụ số (2): thành phần chính và dữ liệu sau khi chiếu

Trị riêng (sắp giảm dần)

	λ	% phương sai	Tích lũy
PC1	1507.2	86.1%	86.1%
PC2	236.5	13.5%	**99.6%**
PC3	6.3	0.4%	100.0%

Vector riêng V_2 (k = 2)

	v_1	v_2
Toán	0.74	0.56
Lý	0.57	−0.22
Anh	−0.36	0.80

$Z = X V_2$ (5 × 3 → 5 × 2)

HS	z_1	z_2
HS1	50.1	−13.7
HS2	24.2	22.6
HS3	0.0	0.0
HS4	−27.9	−14.6
HS5	−46.5	5.8

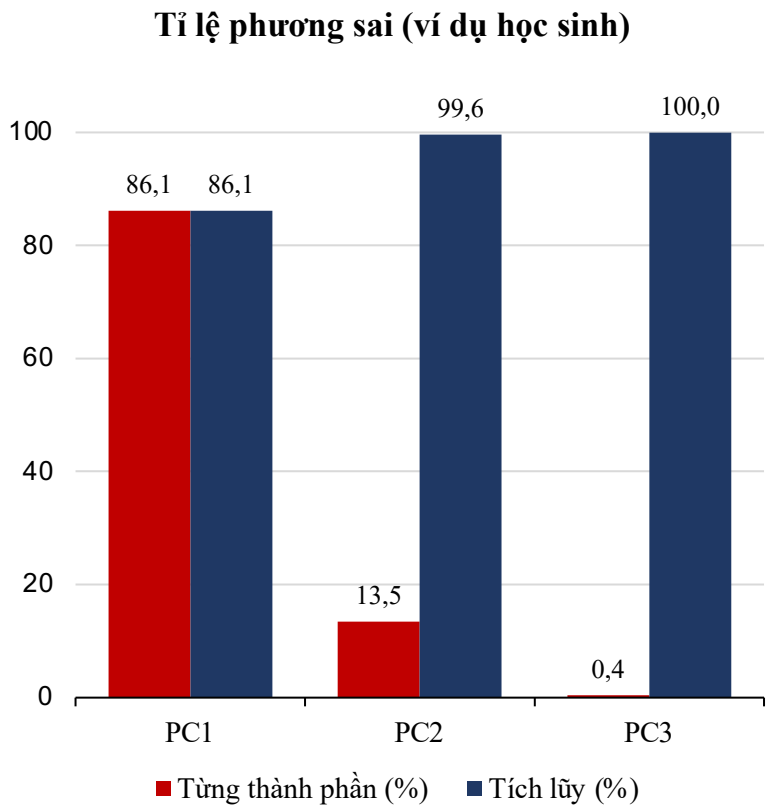
k = 2 giữ **99,6%** phương sai

PC1: Toán, Lý (+) ↔ Anh (−)

Chọn số thành phần K

$$\Sigma_{j=1..k} \lambda_j \;/\; \Sigma_{j=1..n} \lambda_j \geq 0.99$$

- Chọn **k nhỏ nhất** thỏa điều kiện ("99% phương sai được giữ lại")
- Tương đương: sai số chiếu trung bình / tổng biến thiên ≤ 1%
- Ngưỡng 90–95% cũng phổ biến



PCA với ma trận rating: ý nghĩa và giới hạn

Ý nghĩa

- Mỗi user là một điểm trong $\mathbb{R}^n$ (n item)
- Thành phần chính v_j: một **mẫu hình sở thích** trên các item
- $z_u = (x_u - \mu)\, V_k$: hồ sơ **k chiều** của user
- Tính độ tương đồng trên z_u: nhanh hơn, ít nhiễu hơn

Giới hạn

- Cần ma trận **đầy đủ**: ô thiếu phải được điền trước
- Ma trận C có kích thước n × n: rất lớn khi số item lớn
- Chỉ cho đặc trưng của user; item được biểu diễn gián tiếp qua V_k
- → Cần công cụ tổng quát hơn: **SVD**

PHẦN 3

Phân rã giá trị suy biến (SVD)

- Hạng ma trận và định nghĩa SVD
- Ví dụ Users × Movies, diễn giải U, Σ, V
- Truncated SVD và chọn k
- Quan hệ PCA ↔ SVD

Hạng của ma trận = số chiều "thật"

Hạng (rank): số dòng/cột độc lập tuyến tính tối đa của ma trận.

A (3 × 3)

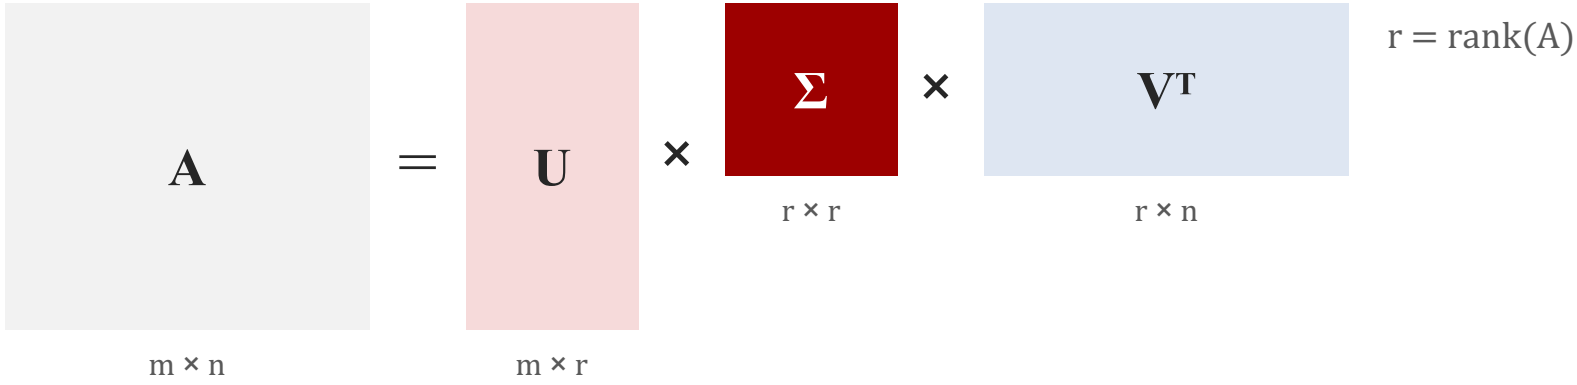
1	**2**	**1**
−2	−3	1
3	5	0

rank(A) = 2

dòng 1 = dòng 2 + dòng 3

- Ma trận rating thực tế không có hạng thấp chính xác, nhưng **xấp xỉ rất tốt** bằng ma trận hạng thấp.
- **SVD cho cách xấp xỉ hạng thấp tốt nhất.**

Định nghĩa SVD



- **U**: vector suy biến trái, $U^TU = I$
- **V**: vector suy biến phải, $V^TV = I$
- **Σ** = diag($\sigma_1 \geq \sigma_2 \geq \ldots \geq \sigma_r > 0$): giá trị suy biến

- **Mọi** ma trận thực đều có SVD
- Cột của V: vector riêng của A^TA; cột của U: vector riêng của AA^T
- σ_i^2 = trị riêng của A^TA

Ví dụ: ma trận Users × Movies

A (7 user × 5 phim)

	Matrix	Alien	Seren.	Casab.	Amelie
U1	1	1	1	0	0
U2	3	3	3	0	0
U3	4	4	4	0	0
U4	5	5	5	0	0
U5	0	2	0	4	4
U6	0	0	0	5	5
U7	0	1	0	2	2

=

U (7 × 3)

c_1	c_2	c_3
0.14	−0.02	−0.01
0.41	−0.07	−0.03
0.55	−0.09	−0.04
0.69	−0.12	−0.05
0.15	0.59	0.65
0.07	0.73	−0.68
0.08	0.30	0.33

×

Σ (3 × 3)

12.48	0	0
0	**9.51**	0
0	0	1.35

Chỉ 3 giá trị suy biến khác 0 vì rank(A) = 3

- Phim 1–3: khoa học viễn tưởng (Sci-Fi)
- Phim 4–5: tình cảm (Romance)
- *Số liệu tính lại bằng NumPy*

× V^T (3 × 5)

Matrix	Alien	Serenity	Casablanca	Amelie
0.56	0.59	0.56	0.09	0.09
−0.13	0.03	−0.13	0.70	0.70
−0.41	0.80	−0.41	−0.09	−0.09

Diễn giải U, Σ, V: "khái niệm" ẩn

U

user ↔ khái niệm

- User 1–4: nặng ở c_1 (Sci-Fi)
- User 5–7: nặng ở c_2 (Romance)

Σ

độ mạnh của khái niệm

- Sci-Fi: $\sigma_1 = 12.48$
- Romance: $\sigma_2 = 9.51$
- c_3: $\sigma_3 = 1.35 \rightarrow$ thành phần yếu, đóng góp ít

V

phim ↔ khái niệm

- Matrix, Alien, Serenity ↔ v_1
- Casablanca, Amelie ↔ v_2

Góc nhìn hình học

v_1 là trục mà dữ liệu trải rộng nhất (như thành phần chính thứ nhất); các cột của **UΣ** là tọa độ của user trên các trục khái niệm.

Truncated SVD: xấp xỉ hạng k

A (hạng 3)

	Matrix	Alien	Seren.	Casab.	Amelie
U1	1	1	1	0	0
U2	3	3	3	0	0
U3	4	4	4	0	0
U4	5	5	5	0	0
U5	0	2	0	4	4
U6	0	0	0	5	5
U7	0	1	0	2	2

$\sigma_3 = 0$

$A_2 = U_2 \Sigma_2 V_2^T$ (hạng 2)

	Matrix	Alien	Seren.	Casab.	Amelie
U1	0.99	1.01	0.99	0.00	0.00
U2	2.98	3.04	2.98	0.00	0.00
U3	3.98	4.05	3.98	−0.01	−0.01
U4	4.97	5.06	4.97	−0.01	−0.01
U5	0.36	1.29	0.36	4.08	4.08
U6	**−0.37**	0.73	**−0.37**	4.92	4.92
U7	0.18	0.65	0.18	2.04	2.04

Eckart–Young: A_k là xấp xỉ hạng k tốt nhất của A theo chuẩn Frobenius

$\|A - A_k\|_F^2 = \sigma_{k+1}^2 + \ldots + \sigma_r^2 \quad \rightarrow \quad$ ở đây $\|A - A_2\|_F = \sigma_3 = 1.35$

Tổng các ma trận hạng 1 và "năng lượng"

$$A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \ldots + \sigma_r u_r v_r^T$$

Năng lượng giữ lại với k thành phần:

$$E(k) = \Sigma_{i \le k} \sigma_i^2 \ / \ \Sigma_i \sigma_i^2$$

- Quy tắc: giữ **80–90%** năng lượng
- Mỗi $\sigma_i u_i v_i^T$ là một "khái niệm"
- Hệ khuyến nghị: k thường 20–200, chọn theo RMSE

k = 1	**62,8%**
k = 2	**99,3%**
k = 3	**100,0%**

Tìm user tương tự trong không gian khái niệm

Rating gốc (5 chiều)

	Matrix	Alien	Seren.	Casab.	Amelie
q	**5**	0	0	0	0
d	0	**4**	**5**	0	0



Không gian khái niệm (2 chiều)

	Sci-Fi	Romance
q	2.81	−0.63
d	5.18	−0.52

cos = 0

trên rating gốc: không có phim chung

cos = 0,99

trong không gian khái niệm

- Không gian ẩn giúp phát hiện tương đồng mà rating gốc **không thấy được**.
- Lưu ý: phép chiếu $q \cdot V_k$ coi phim chưa xem là 0 (giả định của SVD cổ điển, xem slide 34). Với MF, user mới được biểu diễn chỉ từ rating đã biết (slide 36).

Quan hệ PCA ↔ SVD

Cho X (m × n) **đã trừ trung bình theo cột**, với SVD $X = U\Sigma V^T$:

$$C = X^T X / (m-1) = V \Sigma U^T U \Sigma V^T / (m-1)$$
$$\mathbf{C = V \cdot (\Sigma^2 / (m-1)) \cdot V^T}$$

Thành phần chính	Trị riêng	Điểm PCA
= các cột của V	$\lambda_j = \sigma_j^2 / (m-1)$	$Z = X V_k = U_k \Sigma_k$

- Không cần tạo ma trận C (n × n), ổn định số hơn → thư viện (scikit-learn) tính PCA **bằng SVD**.
- Thành phần chính là **vector suy biến phải** của X đã trừ trung bình: PCA **có thể tính bằng** SVD; SVD áp dụng cho mọi ma trận.

So sánh PCA và SVD

Tiêu chí	PCA	SVD
Đầu vào	Ma trận dữ liệu đã trừ trung bình	Ma trận bất kỳ
Phân rã	Trị riêng của $C = X^TX/(m-1)$	$A = U\Sigma V^T$
Kết quả	Thành phần chính V_k, điểm Z	U (user), Σ (độ mạnh), V (item)
Giảm chiều	Giữ k trị riêng λ lớn nhất	Giữ k giá trị suy biến σ lớn nhất
Chọn k	% phương sai giữ lại	% năng lượng $\Sigma\sigma^2$
Trong khuyến nghị	Hồ sơ k chiều của user	$\mathbf{P = U_k\Sigma_k^{1/2}, Q = V_k\Sigma_k^{1/2}}$
Hạn chế chung	Cần ma trận đầy đủ	Cần ma trận đầy đủ

PHẦN 4

SVD cho khuyến nghị và Matrix Factorization

- Dự đoán rating bằng SVD và hạn chế
- Funk SVD: học P, Q chỉ trên rating đã biết
- SGD, ALS, mô hình có bias, đánh giá RMSE
- Thực hành và bài tập

Dự đoán rating bằng SVD: quy trình

1

Điền ô thiếu

0, trung bình user hoặc trung bình item

2

Chuẩn hóa (tùy chọn)

trừ trung bình của từng user

3

SVD, giữ k

$R_k = U_k \Sigma_k V_k^T$

4

Dự đoán

đọc $\hat{r}_{ui}$ tại ô thiếu, xếp hạng Top-N

Liên hệ với dạng Matrix Factorization

$$P = U_k \Sigma_k^{1/2} \ (m \times k), \quad Q = V_k \Sigma_k^{1/2} \ (n \times k) \quad \Rightarrow \quad R_k = P\,Q^T$$

Mỗi user và mỗi item có một vector k chiều trong cùng một không gian.

Ví dụ: dự đoán rating của Alice cho Item5

Ma trận rating (k = 2)

	Item1	Item2	Item3	Item4	Item5
Alice	1	3	3	3	**?**
User1	2	4	2	2	4
User2	1	3	3	5	1
User3	4	5	2	3	3
User4	1	1	5	2	1

- SVD hiểu "0" là **rất ghét**, không phải **chưa biết**.
- Cách điền ô thiếu ảnh hưởng trực tiếp đến dự đoán.

Điền 0

$\hat{r} = 0.84$

I1	I2	I3	I4	I5
1.08	2.24	3.29	2.98	**0.84**

Điền trung bình Alice (2,5)

$\hat{r} = 2.03$

I1	I2	I3	I4	I5
1.63	2.94	3.02	3.01	**2.03**

Hạn chế của SVD cổ điển trong khuyến nghị

1

0 ≠ chưa biết

Phải điền ~99% ô bằng giá trị giả → mô hình học từ dữ liệu giả

2

Ngoài thang điểm

Dự đoán có thể âm hoặc lớn hơn 5 (ví dụ −0,37 ở slide 26)

3

Chi phí lớn

SVD đầy đủ $O(mn \cdot \min(m, n))$; phải tính lại khi có rating mới

4

Điều chuẩn hạn chế

Chỉ kiểm soát độ phức tạp qua hạng k; không có điều chuẩn tường minh trên từng vector user/item

Ý tưởng Simon Funk (2006): **bỏ qua ô thiếu**, học trực tiếp P và Q từ các rating đã biết.

Funk SVD: chỉ học trên rating đã biết

$$\min_{P,Q} \sum_{(u,i)\in\Omega} [(r_{ui} - p_u^T q_i)^2 + \lambda (\|p_u\|^2 + \|q_i\|^2)]$$

sai số trên rating đã biết — *điều chuẩn (regularization)*

Ω	tập các cặp (u, i) **đã có** rating
p_u, q_i	vector k chiều của user u và item i
λ	hệ số điều chuẩn, chống overfitting

"SVD" trong Netflix Prize hay thư viện Surprise thực chất là mô hình này.

So với SVD cổ điển

- Không điền ô thiếu
- Không yêu cầu trực giao
- Có điều chuẩn
- Học dần bằng tối ưu hóa

Ví dụ Funk SVD (1): dữ liệu và mô hình

Ma trận rating R

	Phim 1	Phim 2	Phim 3
An	**5**	**3**	?
Bình	**4**	?	**1**

$\Omega = \{(An,P1), (An,P2), (Bình,P1), (Bình,P3)\}$

- **4 ô đã biết** (tô hồng) tham gia vào hàm mất mát
- **2 ô "?"** bị bỏ qua: **không cần điền** giá trị giả
- Sau khi học xong, ô "?" được dự đoán bằng $p_u^T q_i$

Mô hình hiện tại (k = 2)

Vector	Giá trị	$\|\cdot\|^2$
p_{An}	(2 ; 1)	4 + 1 = 5
$p_{Bình}$	(1,5 ; 0)	2,25 + 0 = 2,25

Vector	Giá trị	$\|\cdot\|^2$
q_1 (Phim 1)	(2 ; 1)	4 + 1 = 5
q_2 (Phim 2)	(1 ; 1)	1 + 1 = 2
q_3 (Phim 3)	(0,5 ; 0)	0,25 + 0 = 0,25

$\|v\|^2$ = tổng bình phương các thành phần của v

Ví dụ Funk SVD (2): tính hàm mất mát

$(u, i) \in \Omega$	r_{ui}	Dự đoán $p_u^T q_i$	$(r_{ui} - p_u^T q_i)^2$	$\|p_u\|^2 + \|q_i\|^2$
An – P1	5	$2\times2 + 1\times1 = 5$	0	$5 + 5 = 10$
An – P2	3	$2\times1 + 1\times1 = 3$	0	$5 + 2 = 7$
Bình – P1	4	$1{,}5\times2 + 0\times1 = 3$	$\mathbf{(4 - 3)^2 = 1}$	$2{,}25 + 5 = 7{,}25$
Bình – P3	1	$1{,}5\times0{,}5 + 0\times0 = 0{,}75$	$\mathbf{(1 - 0{,}75)^2 = 0{,}0625}$	$2{,}25 + 0{,}25 = 2{,}5$
Tổng			**1,0625**	**26,75**

phần đỏ: sai số *phần xanh: điều chuẩn*

$$\text{Loss} = 1{,}0625 + \lambda \times 26{,}75 = 1{,}0625 + 0{,}1 \times 26{,}75 = \mathbf{3{,}74}$$

Học = chỉnh dần P, Q để Loss **giảm** (SGD/ALS, slide sau)

Ví dụ Funk SVD (3): vì sao cần điều chuẩn λ?

Người mới **Cường** chỉ chấm **1 phim**: Phim 1 = 5 sao. Tìm $p_{\text{Cường}}$ sao cho $p_{\text{Cường}}{}^{T}q_1 = 5$, với $q_1 = (2\ ;\ 1)$.

	Vector A: (2 ; 1)	Vector B: (10 ; −15)
Dự đoán Phim 1 (thật: 5)	2×2 + 1×1 = 5 ✓	10×2 − 15×1 = 5 ✓
Sai số²	0	0
Loss khi λ = 0	0	**0 (hòa nhau!)**
Phạt $\lambda(\|p\|^2 + \|q_1\|^2)$, λ = 0,1	**0,1 × (5 + 5) = 1**	**0,1 × (325 + 5) = 33**
Dự đoán Phim 2, $q_2 = (1\ ;\ 1)$	**2 + 1 = 3**	**10 − 15 = −5 ✗**
Dự đoán Phim 3, $q_3 = (0{,}5\ ;\ 0)$	**1 + 0 = 1**	5 + 0 = **5**

λ = 0: Không phân biệt được A và B → có thể chọn B: khớp dữ liệu nhưng đoán −5 sao (**học thuộc**)

λ = 0,1: B bị phạt nặng gấp 33 lần → mô hình chọn vector **nhỏ, thận trọng** như A

Tối ưu hóa: SGD và ALS

SGD

Stochastic Gradient Descent

Với mỗi $(u, i) \in \Omega$, chọn ngẫu nhiên:

$e_{ui} = r_{ui} - p_u^T q_i$

$p_{old} \leftarrow p_u$

$p_u \leftarrow p_u + \eta \, (e_{ui} \, q_i - \lambda \, p_u)$

$q_i \leftarrow q_i + \eta \, (e_{ui} \, p_{old} - \lambda \, q_i)$

SGD: đơn giản, ít bộ nhớ, dễ cài đặt

Siêu tham số: số yếu tố k, hệ số điều chuẩn λ, tốc độ học η, số vòng lặp

Ví dụ SGD (1): một bước cập nhật

Chọn ngẫu nhiên rating **Bình – P1** (thật: 4). $\eta = 0{,}1$; $\lambda = 0{,}1$; $p_{Bình} = (1{,}5\ ;\ 0)$; $q_1 = (2\ ;\ 1)$

1 Tính sai số

$e = r - p_{Bình}^T q_1$

$= 4 - (1{,}5\times 2 + 0\times 1) = 4 - 3 = \mathbf{1}$

$e > 0 \rightarrow$ đoán thấp, cần tăng

2 Lưu vector cũ

$p_{old} = (1{,}5\ ;\ 0)$

để sửa q_1 bằng giá trị trước khi đổi

3 Sửa vector người

$p \leftarrow p + \eta(e \cdot q_1 - \lambda \cdot p)$

$e \cdot q_1 - \lambda p = (2\ ;\ 1) - (0{,}15\ ;\ 0) = (1{,}85\ ;\ 1)$

$\times \eta = (0{,}185\ ;\ 0{,}1)$

$p_{Bình} = (1{,}5\ ;\ 0) + (0{,}185\ ;\ 0{,}1) =$ **(1,685 ; 0,1)**

4 Sửa vector phim

$q \leftarrow q + \eta(e \cdot p_{old} - \lambda \cdot q)$

$e \cdot p_{old} - \lambda q = (1{,}5\ ;\ 0) - (0{,}2\ ;\ 0{,}1) = (1{,}3\ ;\ -0{,}1)$

$\times \eta = (0{,}13\ ;\ -0{,}01)$

$q_1 = (2\ ;\ 1) + (0{,}13\ ;\ -0{,}01) =$ **(2,13 ; 0,99)**

Kiểm tra: $1{,}685\times 2{,}13 + 0{,}1\times 0{,}99 =$ **3,69** (trước: 3, thật: 4) → đã gần đúng hơn

Ví dụ SGD (2): một vòng học và nhiều vòng

Vòng 1: duyệt lần lượt 4 rating đã biết

Rating	e	p_u mới	q_i mới	Đoán sau
An – P1 (5)	0	(1,98 ; 0,99)	(1,98 ; 0,99)	4,90
An – P2 (3)	0,03	(1,96 ; 0,98)	(1,00 ; 0,99)	2,93
Bình – P1 (4)	**1,03**	(1,69 ; 0,10)	(2,11 ; 0,98)	**3,67**
Bình – P3 (1)	0,16	(1,68 ; 0,10)	(0,52 ; 0,00)	0,88

- Rating đoán đúng sẵn ($e \approx 0$) → sửa rất ít
- Rating đoán sai nhiều (Bình–P1) → sửa mạnh nhất

Loss qua các vòng

Vòng	Sai số	Loss
0	1,06	3,74
1	0,15	3,00
2	0,05	2,89
5	0,04	2,86
30	0,04	**2,81**

Sau 30 vòng: An–P3 ≈ **1,09**, Bình–P2 ≈ **2,11** (dự đoán ô "?" = $p_u^T q_i$)
Loss giảm nhanh ở vài vòng đầu rồi chậm dần → dừng khi gần như không giảm nữa

Tối ưu hóa: SGD và ALS

ALS

Alternating Least Squares

Cố định Q, giải từng p_u trên Ω_u:

$p_u = (\Sigma_{i \in \Omega_u} q_i q_i^T + \lambda |\Omega_u| I)^{-1} \Sigma_{i \in \Omega_u} r_{ui} q_i$

Cố định P, giải từng q_i tương tự; lặp đến khi hội tụ

Cùng công thức: thêm **user mới** mà không học lại Q

ALS: song song hóa tốt (Spark MLlib), hội tụ ổn định

Siêu tham số: số yếu tố k, hệ số điều chuẩn λ, tốc độ học η, số vòng lặp

Ví dụ ALS (1): cố định Q, giải từng người

Giữ nguyên $q_1 = (2\ ;\ 1)$, $q_2 = (1\ ;\ 1)$, $q_3 = (0{,}5\ ;\ 0)$. Giải $M \cdot p_u = b$ với $M = \Sigma\, q_i q_i^T + \lambda|\Omega_u| \cdot I$, $b = \Sigma\, r_{ui} \cdot q_i$

Người: An (P1 = 5, P2 = 3)

$\Sigma qq^T = [4\ \ 2;\ 2\ \ 1] + [1\ \ 1;\ 1\ \ 1]$

$\lambda|\Omega| = 0{,}1 \times 2 = 0{,}2 \rightarrow M = [5{,}2\ \ 3;\ 3\ \ 2{,}2]$

$b = 5(2;1) + 3(1;1) = (13\ ;\ 8)$

$\det M = 5{,}2 \times 2{,}2 - 3 \times 3 = 2{,}44$

$p = (2{,}2 \times 13 - 3 \times 8\ ;\ -3 \times 13 + 5{,}2 \times 8) \,/\, 2{,}44$

$p_{An} = (1{,}89\ ;\ 1{,}07)$

Dự đoán (thật): P1: 4,84 (5) P2: 2,95 (3)

Người: Bình (P1 = 4, P3 = 1)

$\Sigma qq^T = [4\ \ 2;\ 2\ \ 1] + [0{,}25\ \ 0;\ 0\ \ 0]$

$\lambda|\Omega| = 0{,}1 \times 2 = 0{,}2 \rightarrow M = [4{,}45\ \ 2;\ 2\ \ 1{,}2]$

$b = 4(2;1) + 1(0{,}5;0) = (8{,}5\ ;\ 4)$

$\det M = 4{,}45 \times 1{,}2 - 2 \times 2 = 1{,}34$

$p = (1{,}2 \times 8{,}5 - 2 \times 4\ ;\ -2 \times 8{,}5 + 4{,}45 \times 4) \,/\, 1{,}34$

$p_{Bình} = (1{,}64\ ;\ 0{,}60)$

Dự đoán (thật): P1: 3,88 (4) P3: 0,82 (1)

Chỉ **một lần giải** cho mỗi người: Loss 3,74 → **2,85**. Mỗi người giải độc lập → làm song song được.

Ví dụ ALS (2): cố định P, giải từng phim, rồi lặp

Giữ nguyên P vừa tính: $p_{An} = (1{,}89\ ;\ 1{,}07)$, $p_{Bình} = (1{,}64\ ;\ 0{,}60)$. Giải từng q_i: **đổi vai người ↔ phim**.

Ví dụ: Phim 1 (An = 5, Bình = 4)

$$M = p_{An}p_{An}^{T} + p_{Bình}p_{Bình}^{T} + 0{,}2\cdot I$$

$$= [6{,}45\ \ 2{,}99\ ;\ 2{,}99\ \ 1{,}69]$$

$$b = 5\cdot p_{An} + 4\cdot p_{Bình} = (15{,}99\ ;\ 7{,}72)$$

$$\det M = 6{,}45\times 1{,}69 - 2{,}99^2 \approx 1{,}98$$

$$\mathbf{q_1 = M^{-1}b \approx (2{,}02\ ;\ 0{,}99)}$$

Phim	Ai chấm	q_i mới
P1	An, Bình	(2,02 ; 0,99)
P2	An	(1,18 ; 0,67)
P3	Bình	(0,52 ; 0,19)

P2, P3 chỉ có 1 người chấm → $|\Omega_i| = 1$, phạt $\lambda\cdot 1$

Lặp: giải P → giải Q → …

Lượt	0	½ (P)	1	2	5
Loss	3,74	2,85	2,81	2,79	**2,79**

Kết quả cuối

An–P3 ≈ **1,22**

Bình–P2 ≈ **2,33**

So sánh SGD và ALS trên cùng ví dụ

	SGD (30 vòng)	ALS (5 lượt)
Mỗi bước làm gì	Sửa nhẹ p_u, q_i theo 1 rating	Giải thẳng cả một phía (P hoặc Q)
Cần chọn thêm	Tốc độ học η	Không cần η
Loss cuối	2,81	2,79
Dự đoán An – P3	**1,09**	**1,22**
Dự đoán Bình – P2	**2,11**	**2,33**
Ưu điểm	Đơn giản, ít bộ nhớ	Hội tụ nhanh, song song hóa tốt

Hai cách khác nhau nhưng **cùng mục tiêu**: làm nhỏ hàm mất mát → dự đoán ô "?" gần nhau

An thích P1, Bình chấm P3 thấp → An–P3 thấp; Bình chấm thấp hơn An → Bình–P2 < 3

Bài tập

Bài 1 · PCA

- Dữ liệu: (1, 1), (2, 3), (3, 2), (4, 4)
- Tính C, trị riêng, vector riêng
- PC1 giữ bao nhiêu % phương sai?
- Chiếu dữ liệu xuống 1 chiều

Bài 2 · SVD

- $A = [\,3 \;\; 0\,;\, 4 \;\; 5\,]$
- Tìm σ_1, σ_2 (gợi ý: trị riêng của A^TA)
- Tính xấp xỉ hạng 1: $A_1 = \sigma_1 u_1 v_1^T$
- Sai số $\|A - A_1\|_F$ bằng bao nhiêu?

Bài 3 · SGD

- $p_u = (1; 0{,}5)$, $q_i = (0{,}8; 1)$
- $r_{ui} = 4$, $\eta = 0{,}1$, $\lambda = 0{,}05$
- Thực hiện 1 bước cập nhật
- So sánh dự đoán trước và sau

Tổng kết và tài liệu tham khảo

1. Yếu tố ẩn: $R \approx P \cdot Q^T$, mỗi user và item là một vector k chiều
2. PCA: tìm hướng phương sai lớn nhất; chọn K theo % phương sai
3. SVD: $A = U\Sigma V^T$; truncated SVD là xấp xỉ hạng k tốt nhất
4. PCA có thể tính bằng SVD của dữ liệu đã trừ trung bình
5. Rating thưa → Funk SVD: học P, Q trên rating đã biết bằng SGD/ALS

Tài liệu tham khảo

- Koren, Bell, Volinsky (2009). Matrix Factorization Techniques for Recommender Systems. IEEE Computer.
- Leskovec, Rajaraman, Ullman. Mining of Massive Datasets, ch. 9 & 11.
- Sarwar et al. (2000). Application of Dimensionality Reduction in Recommender Systems.
- Duvenaud, Zemel, Erdogdu. CSC311: Matrix Factorizations, Univ. of Toronto.
- Yamamoto (2019). Data Engineering: Matrix Factorization, Kyoto Univ.
- Zheng (2015). Matrix Factorization in Recommender Systems, DePaul Univ.