ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN



DS300

HỆ KHUYẾN NGHỊ

Lọc cộng tác (tt)

Item-based Collaborative Filtering

Giảng viên: ThS. Huỳnh Văn Tín
Bộ môn Khoa học Dữ liệu
Khoa Khoa học và Kỹ thuật Thông tin

Nội dung

- Vấn đề lọc cộng tác dựa trên user
- Lọc cộng tác dựa trên item
- Độ đo tương tự
- Vấn đề dữ liệu thưa

Lọc cộng tác dựa trên user

Dự đoán điểm đánh giá của người dùng mục tiêu cho một sản phẩm dựa trên **xu hướng đánh giá của những người dùng tương tự**.

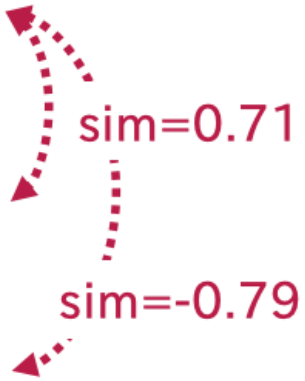
$$predict(u_a, i) = \overline{r_{u_a}} + \frac{\sum_{u \in U_s} sim(u_a, u) \cdot (r_{u,i} - \overline{r_{u_a}})}{\sum_{u \in U_s} sim(u_a, u)}$$

		Item5	sim	Average Rating
	Alice	?	1	4
Similar users	User1	3	0.85	2.4
Similar users	User2	5	0.71	3.8

Pearson's correlation coefficient

$$sim(u_a, u_b) = \frac{\sum_{i \in I}(r_{u_a,i} - \overline{r_{u_a}})(r_{u_b,i} - \overline{r_{u_b}})}{\sqrt{\sum_{i \in I}(r_{u_a,i} - \overline{r_{u_a}})^2}\sqrt{\sum_{i \in I}(r_{u_b,i} - \overline{r_{u_b}})^2}}$$

	Item1	Item2	Item3	Item4
Alice	5	3	4	4
User1	3	1	2	3
User2	4	3	4	3
User3	3	3	1	5
User4	1	5	5	2



Vấn đề của Lọc cộng tác dựa trên user

Nếu hai người dùng chưa đánh giá cùng các sản phẩm, không thể tính được độ tương đồng.

- Hiếm khi có hai người dùng cùng đánh giá một tập mặt hàng.
- Mức độ tương đồng giữa người dùng thay đổi đáng kể nếu thêm một vài đánh giá.

	Item1	Item2	Item3	Item4	item5	item6
Bob					3	2
User1	3	1	2	3		
User2	4	3	4	3		
User3	3	3	1	5		
User4	1	5	5	2		5

Không thể tính toán độ tương đồng.

Liệu có thể tính toán độ tương đồng chính xác giữa người dùng bằng cách chỉ sử dụng điểm đánh giá cho một mặt hàng chung duy nhất hay không?

Vấn đề của Lọc cộng tác dựa trên user

#Users >> #Items

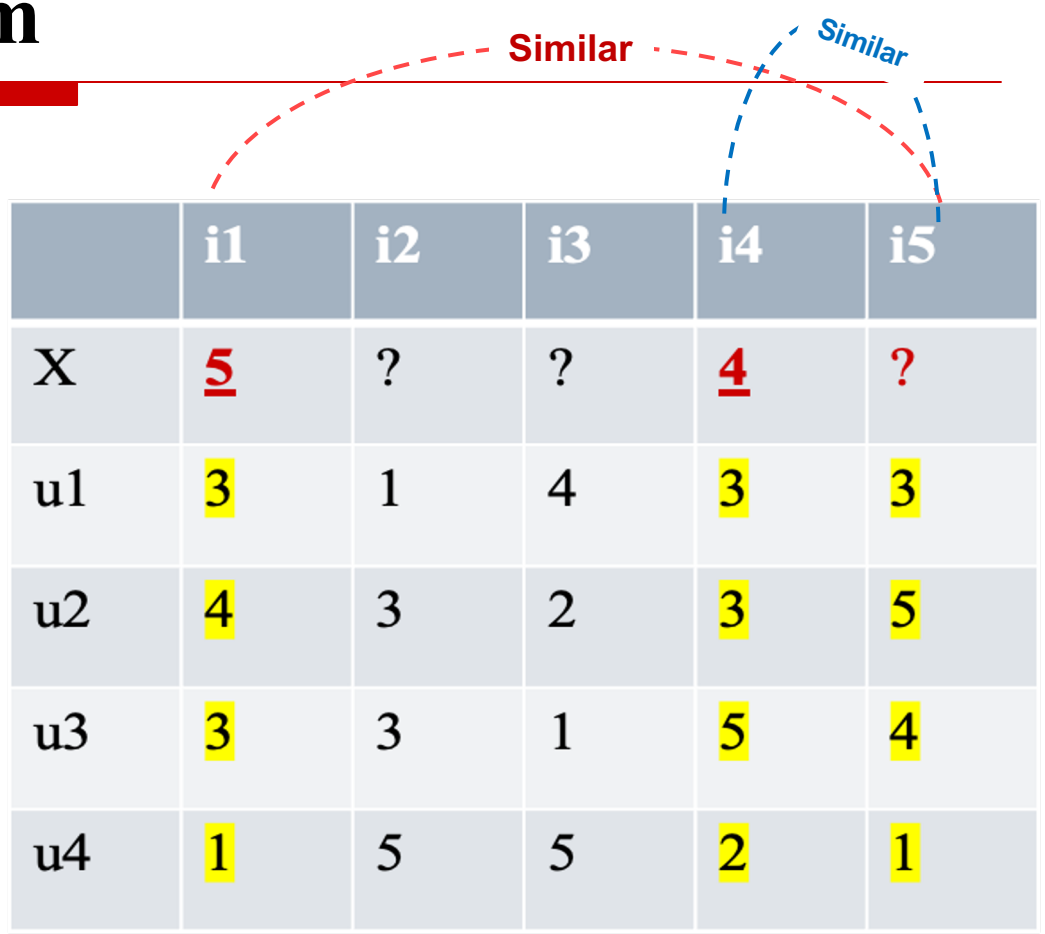
- Nhìn chung, số lượng người dùng lớn hơn nhiều so với số lượng sản phẩm.
- Chi phí tính toán lớn đối với các láng giềng gần nhất (người dùng tương tự)

Unstable user preference

Các tuỳ chọn của người dùng (đặc điểm người dùng) thường thay đổi, trong khi các đặc điểm của sản phẩm thì ít khi thay đổi.

Lọc cộng tác dựa trên item

- Ý tưởng: Dùng sự tương tự trên đối tượng khuyến nghị i (item) để dự đoán giá trị của *f(u,i)* thay vì tương tự dựa trên người dùng u.
- *f(X,i5)* = ?
- Chọn 2 lân cận gần nhất cho i5 → i1,i4. Dựa trên f*(X,i1)* và *f(X,i4)* để tính *f(X,i5)*



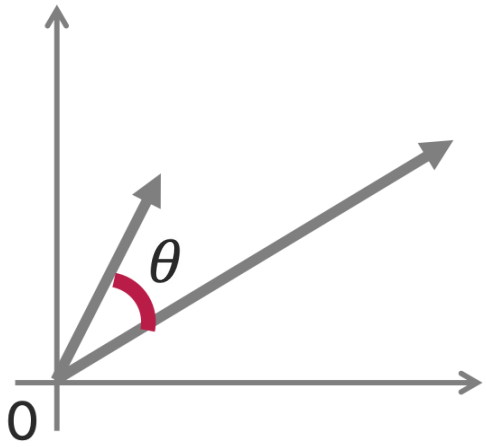
	i1	i2	i3	i4	i5
X	5	?	?	4	?
u1	3	1	4	3	3
u2	4	3	2	3	5
u3	3	3	1	5	4
u4	1	5	5	2	1

Độ đo tương đồng cosine

- Thông tin đánh giá (rating) có thể xem như một vector trong không gian n chiều.
- Với a,b là 2 đối tượng khuyến nghị cần xem mức độ liên quan với nhau

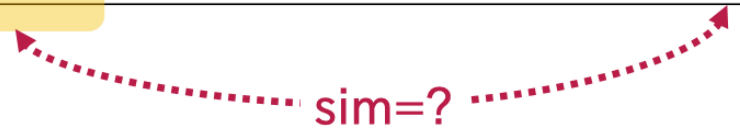
$$\cos\theta = sim(\vec{a},\vec{b}) = \frac{\vec{a}\cdot\vec{b}}{|\vec{a}| * |\vec{b}|}$$

	a	b
X	**4**	**?**
u1	3	3
u2	3	5
u3	5	4
u4	2	1



Vấn đề của cosine

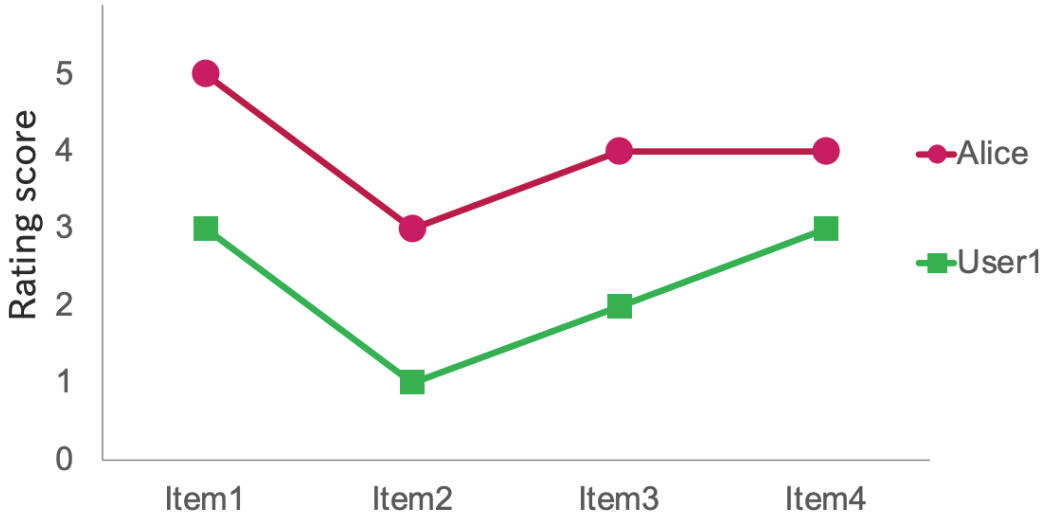
	Item1	Item2	Item3	Item4	Item5
Alice	5	3	4	4	?
User1	3	1	2	3	3
User2	4	3	4	3	5
User3	3	3	1	5	4
User4	1	5	5	2	1



$$sim(i_1, i_5) = \frac{3\times3 + 4\times5 + 3\times4 + 1\times1}{\sqrt{3^2 + 4^2 + 3^2 + 1^2}\times\sqrt{3^2 + 5^2 + 4^2 + 1^2}} = 0.99$$

Vấn đề của cosine

Độ tương đồng cosine cơ bản không tính đến sự khác biệt trong hành vi đánh giá trung bình của người dùng.



Alice đánh giá dễ, còn User1 đánh giá khó. Tuy nhiên, nếu xét đến sự khác biệt so với mức trung bình, thì điểm đánh giá cho Item 1 không khác nhau giữa Alice và User 1.

Độ đo tương đồng Pearson (cosine hiệu chỉnh)

- Với a,b là 2 đối tượng khuyến nghị cần xem xét mức độ liên quan với nhau
- U: tập người dùng cùng có đánh giá trên a, b.
- $r_{u,a}$: đánh giá u trên a

	Item1	Item2	Item3	Item4	Item5
Alice	5	3	4	4	?
User1	3	1	2	3	3
User2	4	3	4	3	5
User3	3	3	1	5	4
User4	1	5	5	2	1

sim=?

Pearson?

$$sim(\vec{a}\vec{b}) = \frac{\sum_{u \in U}(r_{u,a} - \bar{r}_a)(r_{u,b} - \bar{r}_b)}{\sqrt{\sum_{u \in U}(r_{u,a} - \bar{r}_a)^2}\sqrt{\sum_{u \in U}(r_{u,b} - \bar{r}_b)^2}}$$

Cập nhật giá trị ratings

- **Trung bình đánh giá:**

$$r_{u,i} = \frac{1}{|N(i)|} \sum_{j \in N(i)} r_{u,j}$$

N(i): Tập các item lân cận với i

Cập nhật giá trị ratings

- **Tổng hợp đánh giá có trọng số:**

$$r_{u,i} = \frac{\sum_{j \in N(i)} sim(i,j)(r_{u,j})}{\sum_{j \in N(i)} sim(i,j)}$$

N(i): Tập các item lân cận với i

Cập nhật giá trị ratings

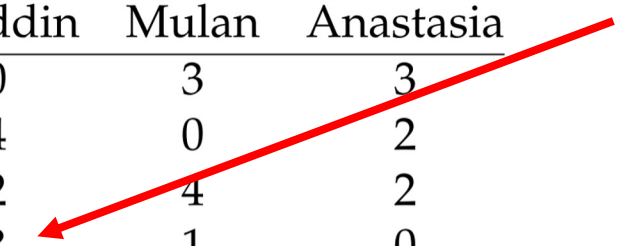
- **Tổng hợp đánh giá dựa trên khoảng cách đánh giá:**

$$r_{u,i} = \bar{r}_i + \frac{\sum_{j \in N(i)} sim(i,j)(r_{u,j} - \bar{r}_j)}{\sum_{j \in N(i)} sim(i,j)}$$

N(i): Tập các item lân cận với i
$\bar{r}_i$: Giá trị rating trung bình của item i
$\bar{r}_j$: Giá trị rating trung bình của item j

Ví dụ

	Lion King	Aladdin	Mulan	Anastasia
John	3	0	3	3
Joe	5	4	0	2
Jill	1	2	4	2
Jane	3	?	1	0
Jorge	2	2	0	1



Dự đoán rating của Jane đối với Aladdin

Ví dụ

	Lion King	Aladdin	Mulan	Anastasia
John	3	0	3	3
Joe	5	4	0	2
Jill	1	2	4	2
Jane	3	?	1	0
Jorge	2	2	0	1

Dự đoán rating của Jane đối với Aladdin

1- tính ratings trung bình

$$\bar{r}_{Lion\ King} = \frac{3+5+1+3+2}{5} = 2.8$$

$$\bar{r}_{Aladdin} = \frac{0+4+2+2}{4} = 2.$$

$$\bar{r}_{Mulan} = \frac{3+0+4+1+0}{5} = 1.6$$

$$\bar{r}_{Anastasia} = \frac{3+2+2+0+1}{5} = 1.6$$

Ví dụ

	Lion King	Aladdin	Mulan	Anastasia
John	3	0	3	3
Joe	5	4	0	2
Jill	1	2	4	2
Jane	3	?	1	0
Jorge	2	2	0	1

Dự đoán rating của Jane đối với Aladdin

2- Tính độ tương đồng giữa hai bộ phim bằng cosine

$$sim(Aladdin, Lion\ King) = \frac{0 \times 3 + 4 \times 5 + 2 \times 1 + 2 \times 2}{\sqrt{24}\sqrt{39}} = 0.84$$

$$sim(Aladdin, Mulan) = \frac{0 \times 3 + 4 \times 0 + 2 \times 4 + 2 \times 0}{\sqrt{24}\sqrt{25}} = 0.32$$

$$sim(Aladdin, Anastasia) = \frac{0 \times 3 + 4 \times 2 + 2 \times 2 + 2 \times 1}{\sqrt{24}\sqrt{18}} = 0.67$$

Ví dụ

3- Tính rating của Jane đối với Aladdin bằng Tổng hợp đánh giá dựa trên khoảng cách đánh giá , giả sử neighborhood size = 2

$$r_{Jane,Aladdin} = \bar{r}_{Aladdin} + \frac{sim(Aladdin, Lion\ King)(r_{Jane,Lion\ King} - \bar{r}_{Lion\ King})}{sim(Aladdin, Lion\ King) + sim(Aladdin, Anastasia)} + \frac{sim(Aladdin, Anastasia)(r_{Jane,Anastasia} - \bar{r}_{Anastasia})}{sim(Aladdin, Lion\ King) + sim(Aladdin, Anastasia)}$$

$$= 2 + \frac{0.84(3 - 2.8) + 0.67(0 - 1.6)}{0.84 + 0.67} = 1.40$$

Ví dụ

❑ Cold start

New user

	p1	p2	p3	p4	p5
Ux	?	?	?	?	?
u1			2		3
u2		3			2
u3	5		1	4	
u4				2	

New item

	p1	p2	p3	p4	Px
u1			2		?
u2			1		?
u3		2			?
u4	5		2	4	?
u5			5		?

Vấn đề dữ liệu thưa

- **Cold start, giải pháp?**
  - Ép người dùng rating
  - Gán giá trị mặc định
  - Dùng thông tin khác (cá nhân, content,...)
  - "Chuyển tiếp/lan truyền" lân cận
  - Graph-based

Ưu điểm của Item-based Collaborative Filtering

Chi phí tính toán

- Thông thường số item ít hơn rất nhiều số người dùng.
- Do đó chi phí tính toán của Item-based CF nhỏ hơn User-based CF.

Tính độ tương đồng ổn định

- Đặc trưng/vector item ít thay đổi và ổn định.
- So với vector người dùng trong rating matrix, vector item có ít chiều bị thiếu dữ liệu hơn.
- Có thể tính độ tương đồng giữa các item dựa trên lượng thông tin đầy đủ hơn.

Ưu/Nhược điểm của Neighborhood-Based Methods

- Ưu điểm
  - Đơn giản, trực quan.
  - Dễ thực hiện và gỡ lỗi.
  - Có thể đưa ra diễn giãi cho một đề xuất.
  - Khuyến nghị ổn định khi có bổ sung sản phẩm hay người dùng mới.
- Nhược điểm
  - Quá trình offline không thực tế quy mô lớn.
  - Phạm vi bao phủ hạn chế do độ thưa thớt.

Bài tập

Trong file bài tập CF

Vấn đề ma trận thưa thớt

Dense Matrix

1	2	31	2	9	7	34	22	11	5
11	92	4	3	2	2	3	3	2	1
3	9	13	8	21	17	4	2	1	4
8	32	1	2	34	18	7	78	10	7
9	22	3	9	8	71	12	22	17	3
13	21	21	9	2	47	1	81	21	9
21	12	53	12	91	24	81	8	91	2
61	8	33	82	19	87	16	3	1	55
54	4	78	24	18	11	4	2	99	5
13	22	32	42	9	15	9	22	1	21

Sparse Matrix

1	.	3	.	9	.	3	.	.	.
11	.	4	.	.	.	.	.	2	1
.	.	1	.	.	.	4	.	1	.
8	.	.	.	3	1	.	.	.	.
.	.	.	9	.	.	1	.	17	.
13	21	.	9	2	47	1	81	21	9
.	.	.	.	.	.	.	.	.	.
.	.	.	.	19	8	16	.	.	55
54	4	.	.	.	11	.	.	.	.
.	.	2	.	.	.	.	22	.	21

Vấn đề ma trận thưa thớt

	3704	1924	4837	867	2631	5410	1733	3536	780	3312	...	207	5817	4097	4755	3977	1520	4622	2160	2542	1535
0	3	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0	0
1	0	3	0	0	0	0	0	0	4	0	...	0	0	0	0	0	0	0	0	0	0
2	0	0	4	0	0	0	5	0	0	0	...	0	0	0	0	0	0	0	0	0	0
3	0	0	0	4	0	0	0	0	4	4	...	0	0	0	0	0	0	0	0	0	0
4	0	0	0	0	5	0	0	0	0	5	...	0	0	0	0	0	0	0	0	0	0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
3671	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0	0
3672	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0	0
3673	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0	0
3674	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0	0
3675	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0	0

3676 rows × 6040 columns

➔ Giảm kích thước (chiều) ma trận nhưng vẫn giữ đặc điểm của dữ liệu

Phân tích thành phần chính - PCA

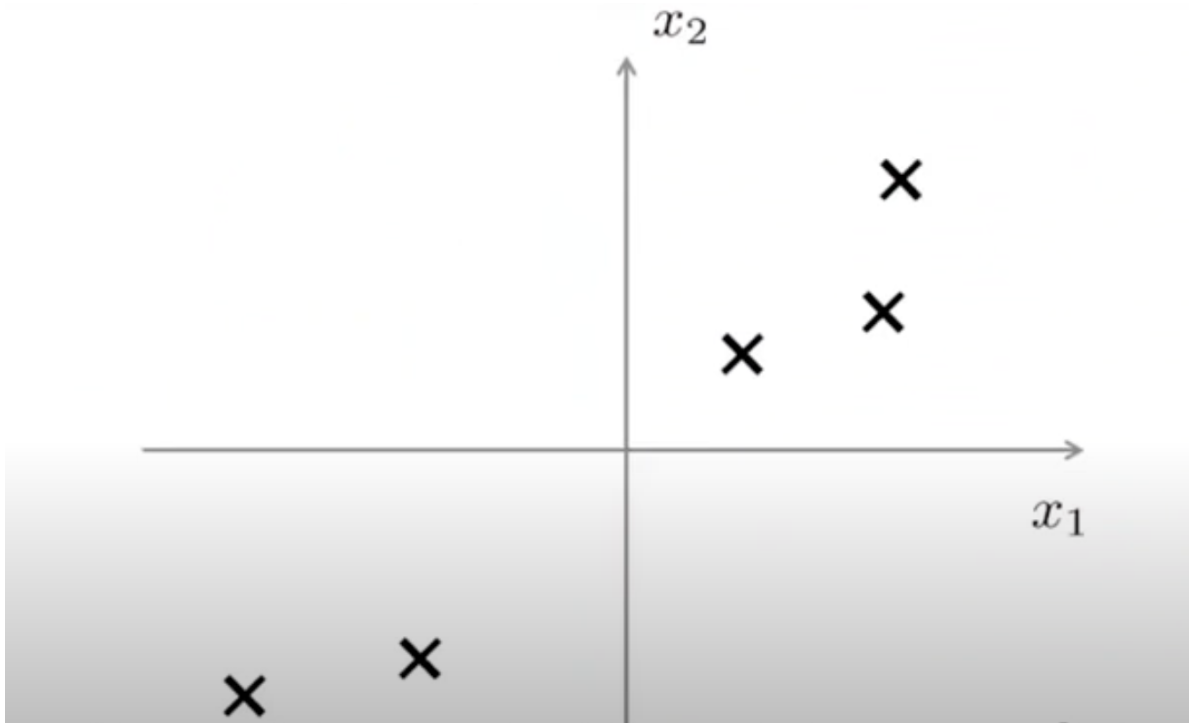
- Phân tích thành phần chính: Principle Component Analysis
- PCA là phương pháp tuyến tính thông dụng nhất để giảm chiều dữ liệu. PCA thực hiện một phép biến đổi tuyến tính, chuyển dữ liệu sang không gian thấp chiều hơn. Khi thực hiện biến đổi, PCA tối đa hóa variance dữ liệu ở không gian thấp chiều.
- Ví dụ dữ liệu của chính ta có N features thì sau khi áp dụng PCA sẽ còn K features chính (K<N).
- Là phương pháp phân tích nhằm giảm chiều dữ liệu (giữ lại những thành phần/biến quan trọng) mà vẫn dữ được các đặc trưng cơ bản của dữ liệu.

Phân tích thành phần chính - PCA

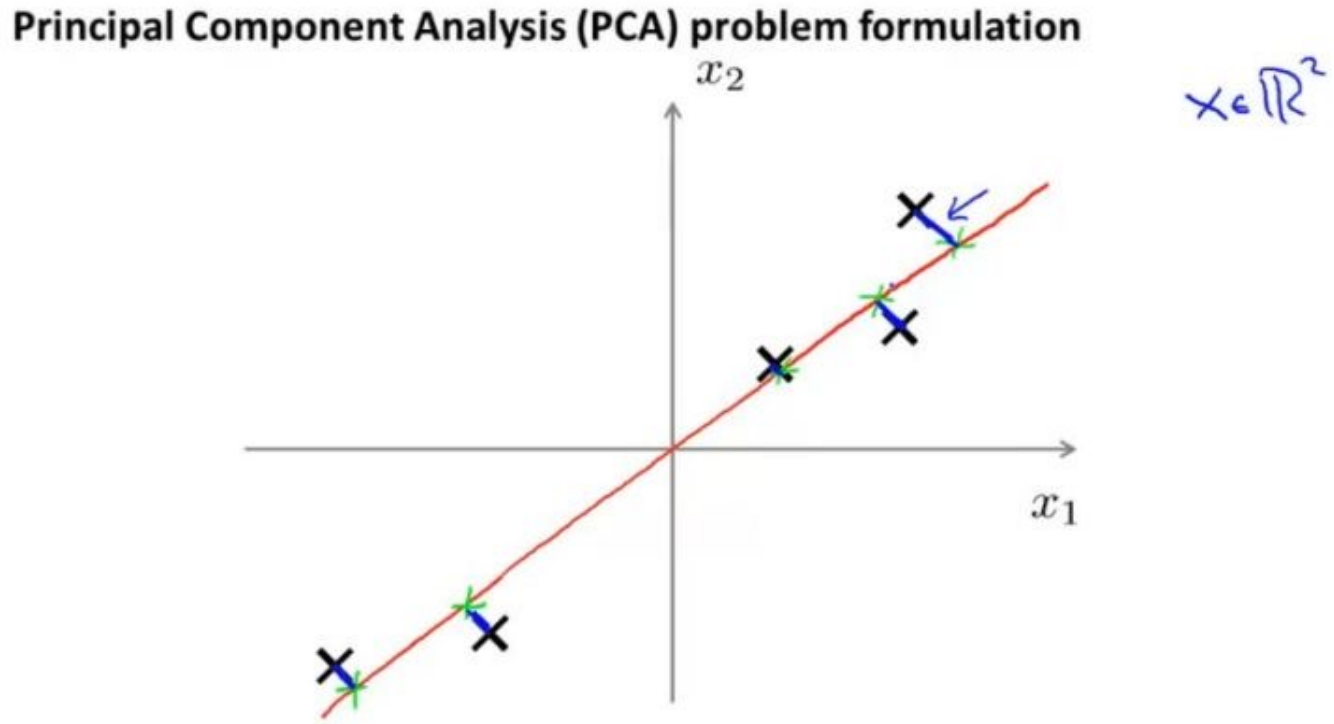
Phân tích PCA sẽ giúp chúng ta:

- Giảm chiều dữ liệu (loại bỏ biến nhiễu và dư thừa) mà vẫn giữ được đặc trưng cơ bản của dữ liệu, chỉ mất đi "chút ít" đặc trưng.
- Tiết kiệm thời gian, chi phí tính toán
- Thuận lợi trong phân tích dữ liệu và vẫn cung cấp cái nhìn trực quan, tổng quát;
- Xác định các biến tương quan.

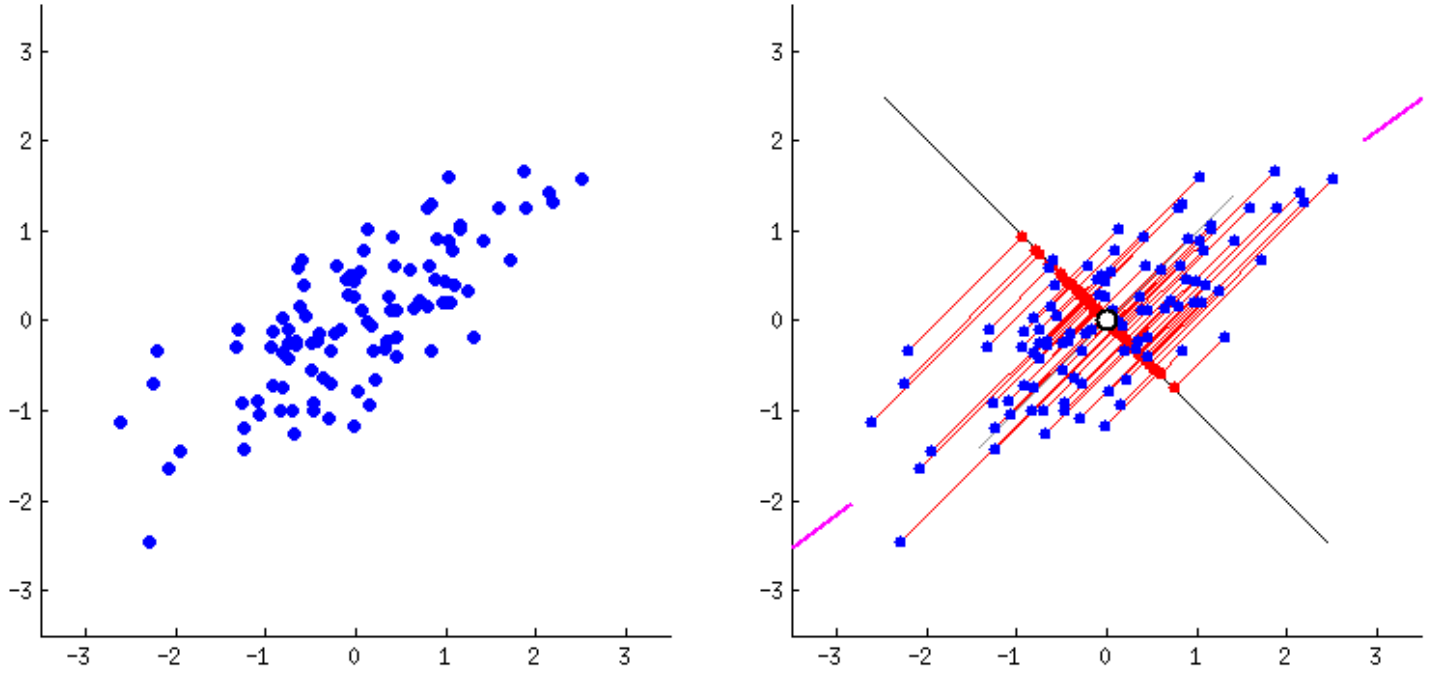
Phân tích thành phần chính - PCA



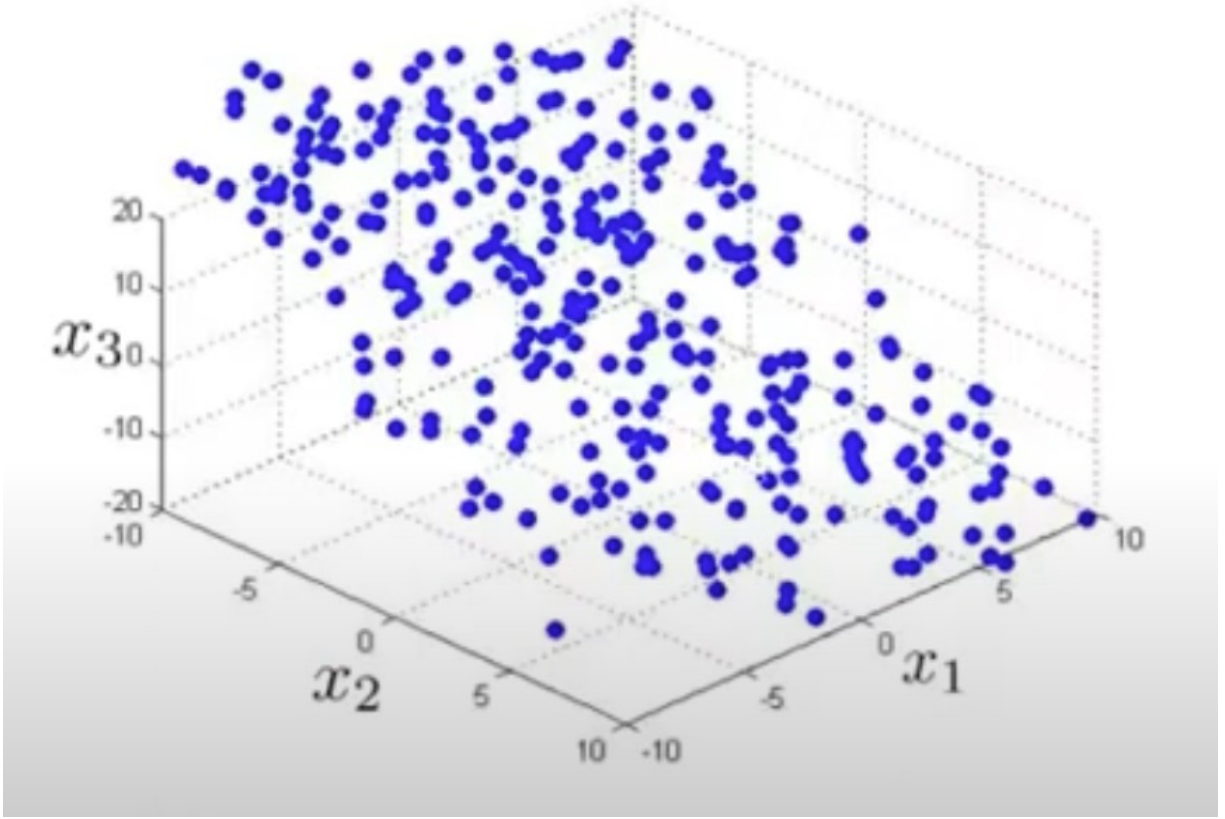
Phân tích thành phần chính - PCA



Phân tích thành phần chính - PCA



Phân tích thành phần chính - PCA



Phân tích thành phần chính - PCA

